

機器學習能否改善 QQQ 短期交易策略? 一個 14 週的實證研究

gre888

2026-09-29

目錄

1	摘要	2
2	研究問題與主旨	2
2.1	研究問題	2
2.2	主旨	2
3	資料與方法論	2
3.1	資料	2
3.2	方法論紀律	2
3.3	統計慣例說明	3
4	階段二: 波動率預測與部位管理	3
4.1	方法	3
4.2	主要結果	3
4.3	隨機基準: 波動目標本身的價值	4
4.4	修正紀錄: 20 日歷史波動率的前視偏誤	4
4.5	穩健性	4
5	階段三: 市場狀態標籤	4
5.1	方法	4
5.2	附帶結果: 論文複現	4
5.3	狀態可事先判定嗎	4
5.4	拿狀態篩選交易日, 能提升策略績效嗎	5
5.5	穩健性	5
6	階段四: 交易日篩選	5
6.1	方法	5
6.2	主要結果與證據階梯	5
6.3	檢定力分析	5
6.4	穩健性: ORB 停利倍數敏感度	5
7	階段五: 深度學習 (CNN)	6
7.1	方法	6
7.2	主要結果	6
7.3	穩健性	6
7.4	診斷: 2020 年 (第 2 折)	6
8	綜合討論: 為什麼難	6
9	限制與未來工作	7
9.1	方法論限制	7

9.2 未來工作	7
10 附錄 A: 修正紀錄	8
11 參考文獻	8

1 摘要

本專題用 14 週時間,系統性檢驗機器學習能否改善 QQQ(納斯達克 100 指數 ETF) 的短期交易策略。研究涵蓋四個依序遞進的方法階段: 波動率預測與部位管理 (階段二)、市場狀態標籤 (階段三)、交易日篩選 (階段四)、深度學習 (階段五)。每個階段都遵循同一套方法論紀律——設定在看任何結果之前寫定、結果不論好壞照實報告、任何事後修正都留下紀錄。

主要發現: 機器學習能改善預測指標,但在扣除實際成本後,無法在現有樣本下顯著改善 QQQ 短期策略的績效。四個階段裡,預測層 (QLIKE、AUC、外部驗證檢定) 經常出現統計上站得住腳的訊號或改善,但策略層 (交易策略本身的 Sharpe 比率) 的觀察差距,除了階段二有明確證據支持「兩者真的沒有實質差異」以外,其餘全部落在現有樣本量檢定力不足以偵測的範圍內。第 10 週的檢定力分析反推,要用現有的資料頻率偵測到 0.2 的 Sharpe 差,需要約 104 年的樣本外資料——這是本篇報告對「為什麼難」最直接的量化。

2 研究問題與主旨

2.1 研究問題

規則型策略 (ORB 開盤區間動能、VWAP 趨勢) 在 QQQ 上是否可以透過機器學習方法改善? 具體而言:(1) 波動率預測能否改善以波動率為基礎的部位管理策略?(2) 市場狀態 (regime) 能否事先判定,並用來篩選規則策略的交易日?(3) 用交易日當天開盤前後的資訊,能否預測一筆訊號值不值得進場?(4) 放棄人工設計特徵、直接用深度學習處理原始分鐘序列,能否得到更多資訊?

2.2 主旨

機器學習能改善預測指標,但在扣除實際成本後,無法在現有樣本下顯著改善 QQQ 短期策略的績效。

這句話裡三個限定詞都是刻意的:「能改善預測指標」——階段二、四、五都有模型在 QLIKE/AUC 這類純預測指標上贏過基準,不是全面沒有訊號。「扣除實際成本後」——策略層的差異顯著性檢定 (block bootstrap) 才是真正的門檻,純預測指標的優勢常常撐不到這一層。「現有樣本下」——檢定力分析 (第 10、14 週) 量化了這不是「還沒找到對的模型」,是現有樣本外 (out-of-sample, OOS) 樣本量在統計上本來就偵測不到這個量級的效果,跟模型好壞無關。

3 資料與方法論

3.1 資料

研究使用 QQQ 的分鐘與日線價量資料 (2014 年 12 月至 2026 年 9 月),以及 VIX/VXN 隱含波動率指數。所有原始資料下載自 Interactive Brokers,清理後存為 parquet 格式,並記錄填充率、異常值等資料品質指標 (第 1 週)。策略層使用的兩個規則策略——ORB(開盤區間動能) 與 VWAP(趨勢跟隨)——複現自 Zarattini 與 Aziz 的日內交易研究 (Zarattini & Aziz, 2023;VWAP 趨勢部分參考 Aziz & Zarattini, 2024 的日內動能策略,經 QuantConnect 重新實作)。

3.2 方法論紀律

本專題橫跨 14 週,每週遵循以下五項方法論原則,構成整份報告最重要的方法論貢獻:

事先寫定設定: 每週的分析設定、成功標準寫進當週的 `config/weekNN_*.toml`, 在看任何結果之前定案; 結果不論好壞照實報告, 不因結果不理想就放寬標準或悄悄多跑幾次換更好看的數字。第 8 週是這項紀律最直接的例子: 原始三項成功標準字面上全部達成, 但補做四項檢查後推翻了「達成」的字面結論 (見「階段四: 交易日篩選」一章)。

巢狀 walk-forward 驗證: 每折訓練段內再切配適 (fit) 段與驗證 (validation) 段, 測試段完全不參與配適或選門檻; 驗證段選定的模型與門檻原封不動套用到測試段, 不重新配適。這個設計避免了「用測試段的資訊挑選模型」這個常見的資料洩漏管道。

截斷與篡改測試: 第五階段 CNN 使用的分鐘序列特徵, 逐一測試截斷 (confirm 特徵在決策時點之後被截斷不影響預測) 與篡改 (confirm 篡改決策時點之後的資料不會改變預測), 確保沒有未來資訊洩漏到序列特徵裡。

隨機基準與 block bootstrap 雙層檢定: 排序層檢定問「模型選中的交易日, 跟隨機選同樣天數比有沒有差」; 策略層檢定 (block bootstrap, 移動區塊拔靴法) 問「篩選前後的績效差本身站不站得住腳」。這兩層經常給出不同答案, 策略層通常比排序層嚴格得多——「階段四: 交易日篩選」一章的證據階梯是這個方法論設計的具體展示。

檢定力分析: 第 10 週引入, 量化「現有樣本量本來就有沒有機會偵測到某個量級的效果」; 第 14 週擴大到 AUC 差, 並補算到階段二、三。這是唯一能回答「是模型不夠好, 還是資料量不夠」這個問題的工具。

3.3 統計慣例說明

本報告策略層的年化 Sharpe 比率, 統一採用算術平均定義 (日報酬平均值除以標準差, 再乘以 $\sqrt{252}$), 跟 block bootstrap 顯著性檢定、最小可偵測差 (MDE) 使用的是同一個定義, 因此報告中「觀察差」欄位會恰好等於兩個 Sharpe 相減。這跟各週報告 (第 5、7、8、12 週等) 顯示的 Sharpe 數字不同——那些週報告顯示的是複利/幾何年化定義 (用複利計算的權益曲線反推年化報酬, 再除以年化波動), 這是全專案自第五週起用於呈現策略績效的慣例。兩種定義本來就分工: 複利定義貼近實際權益曲線、給人報酬感覺; 算術定義在區塊拔靴重抽樣數千次時計算成本低、統計性質更單純, 從第五週起就一直是顯著性檢定內部使用的定義, 只是從未被放進同一張表格直接比較過。第 14 週第一次把兩者放進同一份總表 (`results_summary.json`) 時處理了這個問題, 並確認改用算術定義後, 全部策略層比較的方向 (誰高誰低) 沒有任何一個翻轉, 詳見下表。

表 1: 算術版與複利版年化 Sharpe 差的方向核對 (第 13 週)

階段/列	算術版差	複利版差	方向一致?
phase2/primary	-0.0026	-0.0030	是
phase2/secondary	-0.0161	-0.0193	是
phase3/orb	-0.1566	-0.1502	是
phase3/wap	-0.1026	-0.1178	是
phase4/primary	+0.1714	+0.1903	是
phase5/primary	-0.1997	-0.1894	是

4 階段二: 波動率預測與部位管理

4.1 方法

比較四種已實現波動率 (realized volatility) 預測方法——隨機漫步、HAR(異質自迴歸) 模型、HAR 加上 XG-Boost 殘差修正、20 日歷史波動率——並將預測結果轉換為波動目標 (volatility-targeting) 部位規模, 評估策略層 Sharpe 比率。

4.2 主要結果

預測層: HAR+ 殘差 XGB 對 HAR 的 QLIKE 損失函數差為 -0.0147, Diebold-Mariano 檢定 $p = 0.00045$ (顯著改善)。

策略層: HAR+ 殘差 XGB 對 HAR 的策略 Sharpe 差為 -0.0026 ($p = 0.9173$), 對 20 日歷史波動率的 Sharpe 差為 -0.0161 ($p = 0.8517$)——兩者都不顯著。預測層準確度的改善, 沒有轉化為策略層的顯著改善。

4.3 隨機基準: 波動目標本身的價值

第 14 週補做的隨機基準檢定, 回答了一個不同的問題。主比較問的是「哪個模型的波動預測比較好」(不顯著); 這個隨機基準問的是「真實的波動資訊, 對比打亂日期後的波動資訊, 對這套部位規則有沒有差別」——把 HAR+ 殘差 XGB 的預測值在日期間隨機打亂、重新接回同一套波動目標部位規則, 重複 1000 次, 得到觀察 Sharpe(1.1257) 排在隨機打亂分布的第 96.9 百分位 ($p = 0.0310$, 單尾)。

兩者合起來一致支持階段二的結論: 波動目標部位規則本身有價值, 但哪個模型提供波動預測, 影響不大。這是本專案第一次為「波動目標有價值」這個主張補上正式的統計證據——先前 (第 5 週危機切片一節) 只有「波動目標策略在危機期間最大回撤較淺」這種描述性證據, 沒有正式檢定。

4.4 修正紀錄: 20 日歷史波動率的前視偏誤

在進入階段三之前的全面複查中, 發現 20 日歷史波動率的部位權重計算納入了「當天自己」的收盤到收盤報酬, 構成前視偏誤。修正前該變體的 Sharpe 為 1.4715, 修正後為 1.1568; 修正後, HAR、HAR+ 殘差 XGB、20 日歷史波動率三者的策略 Sharpe 統計上沒有顯著差異。此修正是在看任何階段三結果之前主動查出並修正的 (詳見附錄 A 修正紀錄)。

4.5 穩健性

成本敏感度: 主成本假設下的策略比較, 額外用 3 倍交易成本重跑, 結論 (HAR+ 殘差 XGB 與 HAR 無顯著差異) 不變——用 3 倍成本涵蓋了原訂 2 倍加倍測試的範圍, 較規劃更嚴格。逐年拆解: 各年度 Sharpe 詳見第 5 週報告, 未發現單一年份主導整體結論的情形。參數敏感度: 波動目標水準與槓桿上限的 3×3 組合網格測試, 結論方向一致。

5 階段三: 市場狀態標籤

5.1 方法

用 HMM(隱馬可夫模型) 與 KMeans 對開盤前市場特徵分類為 2-4 個狀態, 評估狀態標籤能否事先判定、以及拿狀態篩選 ORB/VWAP 交易日能否提升策略績效。

5.2 附帶結果: 論文複現

在建立狀態標籤之前, 先複現 ORB 與 VWAP 兩個規則策略, 對照原論文的取樣期間與部位規則: ORB 複現 Sharpe 1.012 對論文 1.13, VWAP 複現 Sharpe 2.339 對論文 2.1, 同一量級, 複現通過。VWAP 複現過程中, 第一次嘗試誤用了 ORB 的部位規則 (每筆風險 1% 權益、4 倍槓桿上限), 得到明顯偏高的複現 Sharpe(3.26) 與過深的最大回撤 (-35.9%); 查出原因後改為 VWAP 自己論文的規則 (100% 權益、不加槓桿、股數每日開盤算死一次), 才得到上表的複現數字 (詳見附錄 A)。

VWAP 在真實交易成本下的 Sharpe 大約只有論文 (近乎零成本假設) 的一半——單位曝險 Sharpe 在論文取樣期間, 主成本下為 1.261, 換成論文近乎零成本假設下為 2.046, VWAP 平均每天反手約 16.6 次, 對成本假設極度敏感。

5.3 狀態可事先判定嗎

用模型外驗證 (predictive-type 狀態分組去解釋一個從未用來配適狀態標籤的真實已實現波動率, Newey-West HAC 標準誤, state 0 為對照組): HMM state 1 對 state 0 的已實現波動差 $t = 9.93$ ($p \approx 0$), state 2 對 state 0 的差 $t = 12.20$ ($p \approx 0$)。狀態標籤本身站得住腳, 不是純雜訊。

5.4 拿狀態篩選交易日, 能提升策略績效嗎

HMM 狀態篩選 ORB: 篩選後 Sharpe 0.2390 對不篩選 0.3956(差 -0.1566, $p = 0.5700$); 篩選 VWAP: 0.9166 對 1.0191(差 -0.1026, $p = 0.4407$)。兩者都不顯著, 且篩選後都比不篩選差。18 個「狀態 vs 全樣本」比較裡, 0 個在 $p < 0.05$ 顯著。

第 14 週補做的逐年拆解確認了這個結論的另一面: 沒有一個狀態連續 8 年都同向為正, 最一致的狀態也只有 7/8 年為正, 最不一致的只有 2/8 年為正——狀態效果沒有年度一致性, 支持「0/18 顯著」是穩健結論, 不是巧合。

5.5 穩健性

成本加倍 (第 14 週補做): ORB、VWAP 兩策略在雙倍交易成本下, 篩選仍然比不篩選差 (ORB 差 -0.1314, VWAP 差 -0.1615), 跟主成本下的方向完全一致。狀態數敏感度: $k=4$ 對照 $k=3$ 的主結果, 結論方向不變。

6 階段四: 交易日篩選

6.1 方法

用交易日開盤前後的 14 個特徵 (隔夜跳空、已實現波動、第一根 5 分鐘 K 線的方向與形態等), 訓練 logistic regression、隨機森林、XGBoost 等模型, 篩選當天的 ORB 訊號值不值得進場。

6.2 主要結果與證據階梯

Logistic 篩選模型的 AUC 為 0.5965(中等)。篩選後 Sharpe 0.7254 對不篩選 0.5540(差 +0.1714), 字面上看起來提升明顯, 但 block bootstrap 顯著性檢定 $p = 0.4845$, 不顯著。

第 8 週建立時, 原始三項成功標準 (篩選後夏普 > 不篩選、篩選後夏普 > 隨機篩選第 95 百分位、每年 ≥ 20 筆交易) 字面上全部達成; 使用者要求補做四項檢查後推翻了這個字面結論——block bootstrap 不顯著、效果集中在兩個極端年份 (2022 大幅為負、2026 大幅為正) 部分抵銷、成本敏感度是唯一完全正面的結果。此事直接促成第 9 週把 block bootstrap $p < 0.05$ 明訂為四項嚴格成功標準之一。五個模型 (logistic、隨機森林、XGBoost 深度 2/3、Huber 迴歸) 沒有一個四項標準全過, 樹模型還出現嚴重過擬合, 詳見下表。

表 2: 第 9 週樹模型過擬合差距 (配適段 AUC- 測試段 AUC)

模型	配適段 AUC	測試段 AUC	差距
logistic	0.667	0.612	0.056
隨機森林	0.828	0.620	0.207
XGBoost(深度 2)	0.901	0.591	0.310
XGBoost(深度 3, 附錄)	0.965	0.591	0.373

6.3 檢定力分析

第 10 週的檢定力分析回答了「現有樣本量本來就有機會偵測到這個量級的效果嗎」: 5% 顯著、80% 檢定力下的最小可偵測 Sharpe 差為 0.6923, 遠大於實際觀察到的 0.17-0.22。反推要用現有的資料頻率偵測到 0.2 的 Sharpe 差, 需要約 104 年的 OOS 資料——這不是換模型或多等一兩年能解決的量級落差。

6.4 穩健性: ORB 停利倍數敏感度

第 14 週補做: ORB 的停利設定從論文預設的 10R, 分別改成 5R 與 15R 重跑 (沿用第 8 週以 10R 標籤訓練出的篩選決定, 不重新訓練模型), 檢驗的是同一批被選中的交易日, 換算到不同停利定義下報酬, 篩選是否仍然較好。5R 下篩選對不篩選差 +0.2403($p = 0.3065$), 15R 下差 +0.1462($p = 0.5440$)——篩選優於不篩選的方向在 5R、10R、15R 三個停利定義下都一致, 三者都不顯著, 跟主結果「方向正但不顯著」的型態吻合, 不是矛盾。

成本加倍、驗證窗網格、保留比例網格等第 10 週的其餘穩健性檢查, 詳見附錄與第 10 週報告。

7 階段五: 深度學習 (CNN)

7.1 方法

放棄人工設計的開盤特徵, 把開盤前後的分鐘級價量序列直接餵給一個小型 1D 卷積神經網路 (1809 個參數), 用 5 個固定種子訓練並平均機率, 跟第 8 週手工特徵 logistic 模型比較。任務 A: 開盤前 5 根 1 分鐘 K 線, 預測 ORB 淨報酬是否為正; 任務 B: 開盤後 N=15、30 分鐘, 預測到收盤的方向。CNN 架構、訓練流程、種子從第 11 週定案後凍結到第 13 週, 不曾因結果不理想而調整。

7.2 主要結果

CNN 對手工特徵 logistic 的 AUC 差為 -0.0554(block bootstrap $p = 0.0008$, 顯著更差)——CNN 不但沒有超出手工特徵的資訊, 反而顯著更差。三項增量資訊檢查 (CNN 分數與手工特徵的 Spearman 相關、CNN logit 對手工特徵的 OLS 迴歸 R^2 、CNN 分數與手工特徵堆疊的增量測試) 一致確認 CNN 沒有超出手工特徵的資訊。策略層: CNN 篩選 Sharpe 0.2213 對不篩選 0.4211(差 -0.1997, $p = 0.4700$, 不顯著)。

任務 B(開盤後 15、30 分鐘序列預測剩餘時段方向) 在 AUC 層與策略層都一致確認沒有可用訊號, 兩個時間窗口的結論一致。

7.3 穩健性

第 14 週補做的逐年拆解: CNN 篩選在 8 年中只有 4/8 年優於不篩選——沒有一致優勢, 呼應「沒有增量資訊」的主結論。成本加倍下, 篩選仍比不篩選差 (差 -0.1811), 跟主成本下的方向一致。CNN 架構本身的參數敏感度未重新打開 (架構凍結是本專案既有紀律, 第 14 週指示下不重開這個決定), 但兩個間接證據可以部分回答設計選擇是否穩健: 任務 B 的 N=15、N=30 兩個獨立時間窗給出一致結論, 不是單一窗口的偶然; 每折 5 個固定種子的測試 AUC 範圍 (見第 12 週報告) 顯示初始化變異的量級遠小於「CNN 比手工特徵差」這個結論的效果量。

7.4 診斷: 2020 年 (第 2 折)

CNN 在第 2 折 (2020 年, COVID 崩盤與反彈) 的測試 AUC 降到 0.4483(低於隨機), 是 8 折裡表現最差的一折。描述性分析確認 2020 年是樣本期間市況最極端的年份之一 (年化波動、VIX、大幅波動天數都是數一數二)。這裡僅做描述, 不修正任何已報告的合併或逐折數字。

8 綜合討論: 為什麼難

四個階段的模式高度一致: 預測層 (QLIKE、AUC、外部驗證檢定) 經常有統計上站得住腳的訊號或差異, 但策略層的觀察差全部遠小於 5% 顯著、80% 檢定力下的最小可偵測差, 如下圖與下表所示。

表 3: 策略層觀察差 vs 最小可偵測差 (算術平均 Sharpe 定義), 全部讀自 results_summary.json

階段	策略層觀察差	p 值	MDE	達 MDE?	判讀
phase2	-0.0026	0.9173	0.0686	否	有檢定力支持的沒有實質差異
phase3	-0.1566	0.5700	0.7864	否	偵測不到
phase4	+0.1714	0.4845	0.6923	否	偵測不到
phase5	-0.1997	0.4700	0.7830	否	偵測不到

但這不是同一種「測不到」: 階段二的最小可偵測差只有 0.0686——不同波動預測模型接同一套部位規則後, 產生的部位序列高度相關, 配對比較的變異數本身就小, 檢定力足夠高。觀察差 (-0.0026) 遠低於這個小的門檻, 是有檢定力支持的「沒有實質差異」, 不是量不到, 是真的量出來很小。階段三到五的最小可偵測差落在 0.69–0.79 這個大得多的量級——樣本量 (交易日數) 沒有本質改變, 但效果本身混在整體策略報酬的雜訊裡, 檢定力不足。這三個階段是偵測不到, 不是偵測到沒有差異——如果背後真有一個中等大小的效果, 現有樣本量本來就看不出來, 不能倒過來說「證明沒有效果」。




圖 1: 各階段策略層觀察差 (算術平均 Sharpe, 保留正負號) 與 $\pm$ 最小可偵測差區間; 資料範圍見各階段自己的 OOS walk-forward 測試段 (階段二 2015-2026、階段三 2020-2026 共同範圍、階段四 2018-2026、階段五 2019-2026)

第 10 週的反推把這個落差量化到具體年限: 要用現有的資料頻率偵測到 0.2 的 Sharpe 差, 需要約 104 年的 OOS 資料——這是全篇報告對「為什麼難」最直接的量化, 不是換模型或多等一兩年能解決的量級落差。

四個階段疊加起來看, 主旨的三個限定詞各自都有直接證據: 「能改善預測指標」——階段二、四、五都有預測層的統計顯著改善或有效訊號; 「扣除實際成本後」——策略層的 block bootstrap 檢定是所有模型共同卡住的地方; 「現有樣本下」——兩次獨立的檢定力分析 (第 10 週 Sharpe、第 14 週 AUC) 從不同指標得到一致結論。

9 限制與未來工作

9.1 方法論限制

樣本量是貫穿全專案的根本限制, 不是任何單一階段的執行問題——這一點被兩次獨立的檢定力分析從不同角度確認。2022 年的方向性弱點 (階段四的做空訊號排序顛倒) 目前只由三個共用同一組特徵、訓練窗高度重疊的模型「發現」, 只能算一個假說, 不是三次獨立驗證。任何看完全部結果後才挑選的探索性組合 (如階段四的兩特徵 logistic 模型), 都打上探索性折扣, 不能當作下一步的起點直接採用。

9.2 未來工作

1. 調查 2022 年做空訊號排序顛倒的具體機制 (階段四附帶發現, 已描述但未深入歸因)。
2. 更長記憶的深度學習架構 (LSTM、Transformer) 列為未來工作, 但前提是有明顯更長的分鐘級歷史資料可用才成立——現有樣本量下, CNN (1809 個參數) 的過擬合差距已經不小, 參數更多的架構需要更多資料才能負責任地訓練, 不是更少。
3. 若未來樣本量顯著增加 (更長歷史或更高頻率的獨立訊號), 值得重新評估檢定力是否改善到可行範圍——但依現有的反推, 這不是短期內可行的方向。

10 附錄 A: 修正紀錄

本專題共 6 條重要的方法論修正, 逐條列出發現方式、影響範圍、修正後結論。全部條目都回頭查證過原始 commit 或報告文字, 不是憑印象轉述。

表 4: 修正紀錄 (逐條查證過原始 commit/報告文字)

週	標題	發現方式	影響範圍與修正後結論
5	20 日歷史波動部位權重的前視偏誤	進入階段三之前主動做的全面前視偏誤複查 (不是被結果異常倒逼發現)	hist20 變體的滾動窗納入當天自己的收盤到收盤報酬; 修正前 Sharpe 1.4715、修正後 1.1568。修正後: 修正後 HAR、HAR+ 殘差 XGB、20 日歷史波動三者 Sharpe 統計上無顯著差異
6	HMM 樣本外狀態解碼漏了測試段第一天的轉移步驟	寫 test_forward_filter_init_dist_seeds 測試段第一天的初始化, 在 commit c3e15b1, 在看任何第 6 週結果之前就抓到並修正	forward_filter 手寫前向演算法, 測試段第一天的初始化改成全新序列起點, 沒有從訓練段最後一天的信念狀態往前轉移。修正後: 修正後才產生 week06_regimes.md 報告的全部 HMM 樣本外狀態數字
6	VWAP 論文複現誤用 ORB 的部位規則	看到異常結果後查出: 第一次複現 Sharpe 3.26、最大回撤-35.9%, 遠超論文的 2.1/-0.094	VWAP 複現誤套用 ORB 的「每筆風險 1% 權益、4 倍槓桿上限」規則, 而不是 VWAP 自己論文的「100% 權益、不加槓桿、股數當日開盤算死」規則。修正後: 改為 1 倍槓桿、每天開盤算一次股數後, 複現 Sharpe 2.339、最大回撤-0.0957, 同論文 2.1/-0.094 同一量級
7	跨狀態來源比較的日期範圍不一致	config/week07_regime_eval.toml 內建的跨折對齊修正, 以及報告內波動三分位只覆蓋第 2-8 折的說明	三個狀態來源 (HMM、KMeans、波動三分位) 的可用日期範圍不同, 直接比較「不篩選」欄位不是同一組交易日。修正後: 改在共同涵蓋日期範圍 (2020-01-02..2026-09-22, 1689 天) 上比較
8	原始三項成功標準沒有一項是差異顯著性檢定	使用者在定稿前要求補四項檢查 (block bootstrap、逐年拆解、成本敏感度), 推翻了字面「三項全過」的結論	篩選後 Sharpe 0.707 對不篩選 0.517 字面達成, 但 block bootstrap p=0.485 不顯著, 效果集中在兩個極端年份部分抵銷。修正後: 第 9 週起把 block bootstrap p<0.05 明訂為四項成功標準之一
10	隨機篩選基準重估種子的蒙地卡羅精度不足	n_reps=1000 時 5 個種子的 p 值在 0.030-0.051 間跳動, 當時解讀成「排序層不穩健」	n=1000 在 p≈0.04 附近標準誤約 0.006, 5 個種子 0.021 的全距大半是估計精度不足的雜訊。修正後: 改用 n_reps=10000 重估, 3 個種子穩定落在 0.042-0.047, 排序層結果其實穩定

11 參考文獻

Zarattini, C., & Aziz, A. (2023). Can Day Trading Really Be Profitable? Evidence of Sustainable Long-term Profits from Opening Range Breakout (ORB) Day Trading Strategy vs. Benchmark in the US Stock Market. SSRN Working Paper No. 4416622.

Aziz, A., & Zarattini, C. (2024). Beat the Market: An Effective Intraday Momentum Strategy for S&P500 ETF (SPY). SSRN Working Paper No. 4824172.

註:VWAP 趨勢策略的實作參考 QuantConnect 對上述日內動能策略的公開重現 (見 *src/rules.py* 模組說明), 而非直接對照論文原始程式碼; 引用資訊透過網路搜尋交叉核對, 論文標題與 SSRN 編號未逐一向原始來源覆核全文內容。